HAW Kiel
Hochschule für Angewandte Wissenschaften Kiel
Kiel University of Applied Sciences

Data Science

Was bedeutet Data Science für den Informatikunterricht?

Prof. Dr. Tillmann Schwörer
HAW Kiel

Agenda

- Begriff Data Science
- Masterstudiengang Data Science der HAW Kiel
- Vertiefung 1: Preisprognose für Berliner Ferienwohnungen
- Vertiefung 2: Datenschatz "Sprache"
- (Weitere) Ideen für den Unterricht

Link zu Materialien

https://github.com/tillschwoerer/ds-informatik-berlin

Begriff „Data Science“

Was ist Data Science?

The term “Data Science” has emerged only recently to specifically designate a new profession that is expected to make sense of the vast stores of big data.

But making sense of data has a long history and has been discussed by scientists, statisticians, librarians, computer scientists and others for years.

Forbes, “A Very Short History Of Data Science” (2013)

https://www.forbes.com/sites/gilpress/2013/05/28/a-very-short-history-of-data-science/#65790a8755cf

Was ist Data Science?

The term “Data Science” has emerged only recently to specifically designate a **new profession** that is expected to make sense of the vast stores of big data.

But making sense of data has a **long history** and has been discussed by scientists, statisticians, librarians, computer scientists and others for years.

Forbes, “A Very Short History Of Data Science” (2013)

https://www.forbes.com/sites/gilpress/2013/05/28/a-very-short-history-of-data-science/#65790a8755cf

Ziel: Daten verstehen

"Making sense of data"

- aus Daten Erkenntnisse ableiten
- informierte, evidenzbasierte Entscheidungen treffen
- Probleme lösen

Neue Herausforderungen

Die Datenmenge steigt rasant

- Volume, variety, velocity, veracity, value ("5 V's of big data")
- Internet, Soziale Medien, Smartphones, Sensordaten, Industrie 4.0

Immenses Potenzial vs komplexe Anforderungen

- Wie speichere, verarbeite, analyse ich große Datenmengen effizient?
- Wie skaliere und automatisierte ich Prozesse?

Kombiniertes Wissen

" [...] the knowledge among **computer scientists** about how to think of and approach the analysis of data is limited, just as the knowledge of computing environments by **statisticians** is limited."

"It carries statistical thinking to **subject matter disciplines** [...] data science is practiced by statisticians and subject matter analysts alike"

William S. Cleveland, 2001, International Statistical Review, „Data Science: an Action Plan for Expanding the Technical Areas of the Field of Statistics”

https://zhanksun.github.io/files/DataScience.pdf

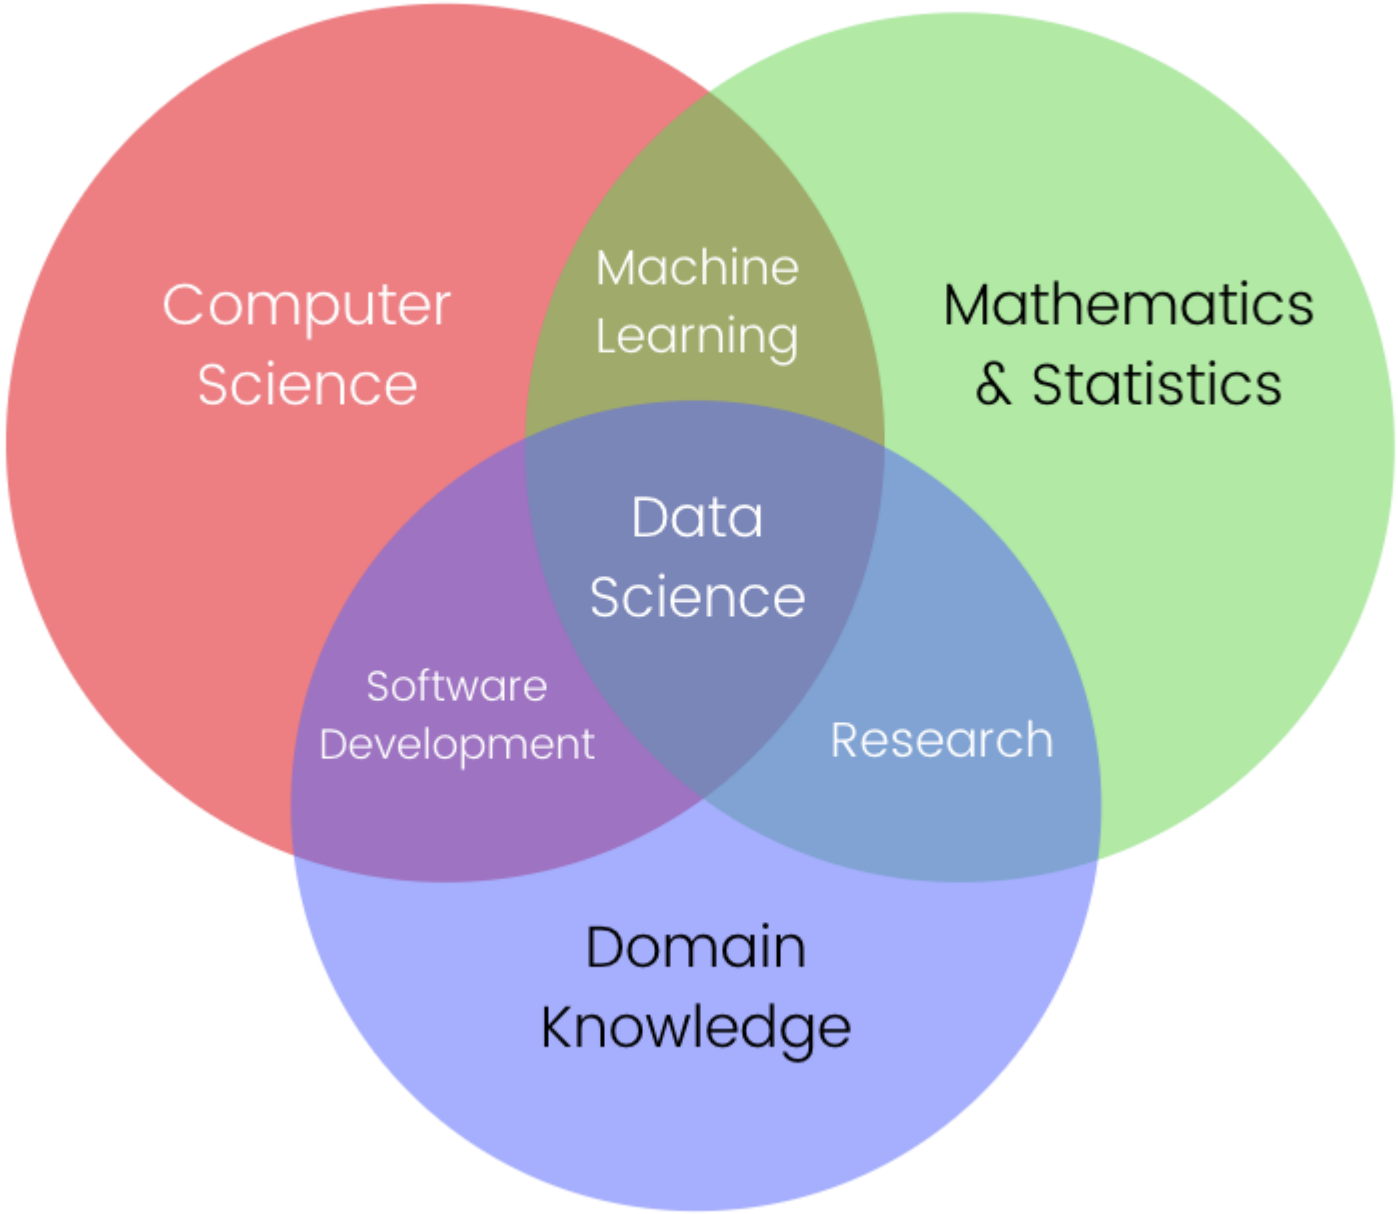

Adaptierte Version von [Drew Conway, 2013]

Masterstudiengang Data Science
HAW Kiel

Data Science an der HAW Kiel

- Abschluss: Master of Science
- Dauer: 3 Semester
- Unterrichtssprache: englisch
- Anwendungsorientiert: Projekte und Thesen mit Unternehmen
- Interdisziplinär

Link zum Studiengang

https://www.haw-kiel.de/studium/studienangebot/data-science/

Interdisziplinarität

Umfrage unter unseren Data Science Master-Studierenden: Was habt ihr davor im Bachelor studiert?

4 x Informatik

3 x Psychologie

3 x Elektrotechnik

3 x BWL

2 x Wirtschaftsinformatik

Gesundheitstechnik

2 Medieninformatik

Bauingenieur

VWL

2 x Wirtschaftsingenieur

Mathematik

Master Data Science an der HAW Kiel

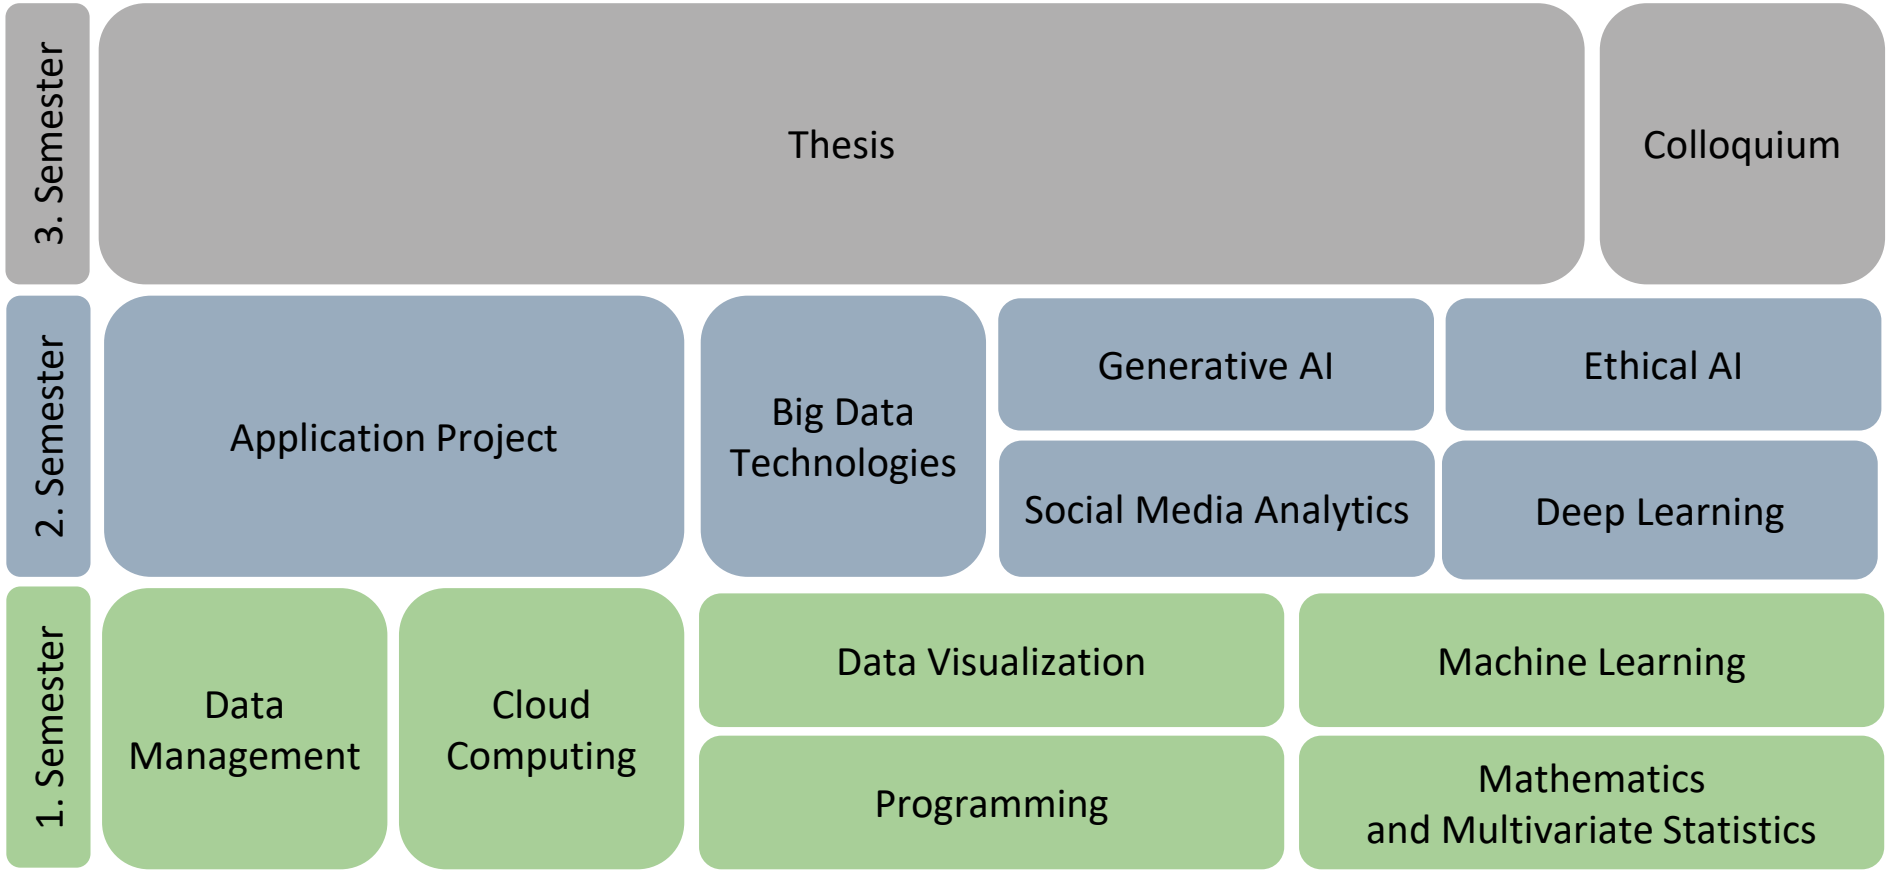

Beispiele für Studentische Praxisprojekte

Optimierung der Kieler Leihfahrräder

Optimierung der Kieler Leihfahrräder

Problem: Leihfahrrad-Stationen sind oft leer oder überfüllt

Aufgabe: Vorhersagemodells zur Optimierung der Fahrrad-Stationierung

Ansatz:

- Daten zu Stationsauslastung und Wetter
- Überwachtes maschinelles Lernen
- Modell macht 5-Stunden-Vorhersagen

Anomalieerkennung im Fernwärmenetz

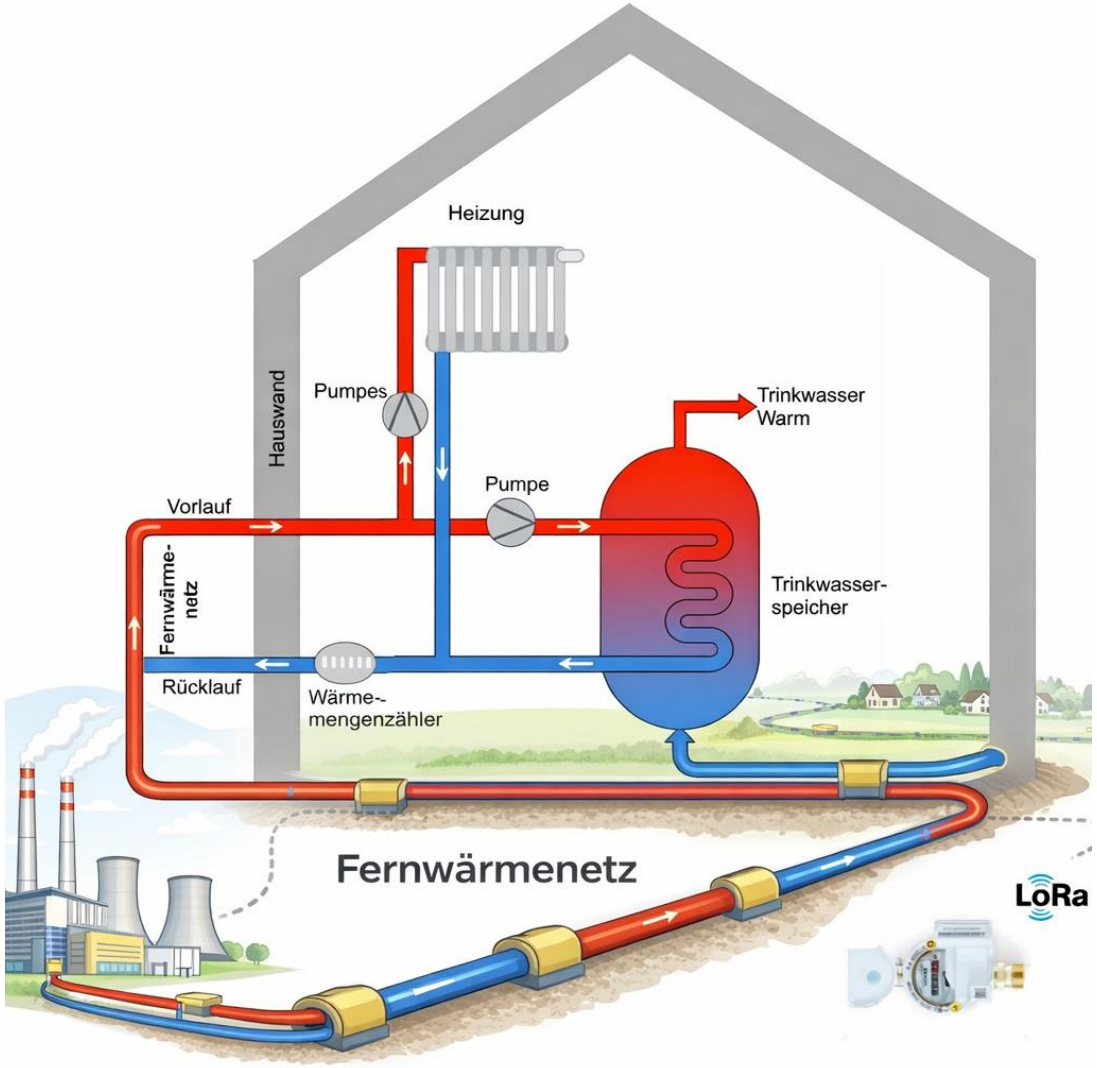

Anomalieerkennung im Fernwärmenetz

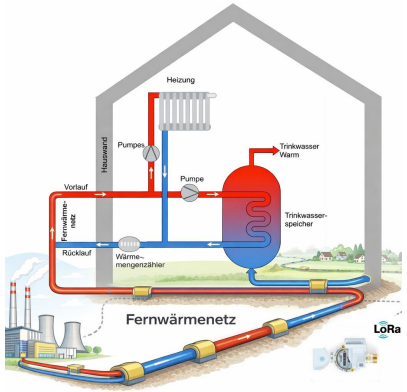

Problem: Durch Leitungsschäden kommt es oft zur Frischwasser-Kontamination und dadurch zu Verkalkungen des Fernwärmnetzes.

Aufgabe: Schäden sollen frühzeitig erkannt werden

Ansatz:

- Sensoren erfassen Wasserdurchfluss und -temperatur
- Unüberwachtes maschinelles Lernen: Abweichungen vom normalen Verlauf identifziert

Korrosionserkennung im Hafen

https://nachrichten.idw-online.de/2024/09/12/mit-ki-gegen-korrosion

Korrosionserkennung im Hafen

Problem: Korrosion an Hafenanlagen erzeugt hohe Instandhaltungskosten

Aufgabe: Korrosion automatisiert anhand von Bildern erkennen

Ansatz:

- Hunderte Bilder werden manuell gelabelt, ob und wo sie Korrosion enthalten (Ground Truth)
- Neuronale Netze werden trainiert um das Vorhandensein und die genaue pixelweise Position von Korrosion vorhersagen zu können

Vertiefung 1:
Preisprognose für Berliner Ferienwohnungen

Mithilfe von überwachtem maschinellen Lernen

Warum ist das interessant?

Vermieter

- Welchen Preis kann ich verlangen?
- Lohnt sich das Aufstellen eines zusätzlichen Bettes finanziell?

Mieter

- Was ist der „typische“ Marktpreis?
- Wie kann ich ein Schnäppchen machen?

AirBnB

- Können wir den Absatz ankurbeln, indem wir auf der Webseite das Preis-Leistungsverhältnis sichtbar machen?

Mögliche Preisdeterminanten

7 Gäste · 2 Schlafzimmer · 2 Betten · 4 Badezimmer
★ 4,69 · 16 Bewertungen

Features

Gastgeber:in ist Alex
Seit 7 Jahren Gastgeber:in

Eigenständiger Check-in
Checke per Schlüsselbox selbst ein.

Kostenlose Stornierung vor dem 15. April
Falls du es dir anders überlegst, erhältst du eine vollständige Rückerstattung.

insgesamt 303 €

Target

CHECK-IN 16.4.2026
CHECK-OUT 17.4.2026
GÄSTE 1 Gast

0 € heute · Kostenlose Stornierung vor dem 15. April

Reservieren

Du musst noch nichts bezahlen.

Das bietet dir diese Unterkunft

- Küche
- Arbeitsplatz
- Fernseher mit Normaler Kabelanschluss
- Privater Innenhof oder Balkon
- Babybett
- WLAN
- Kostenfreie Parkplätze auf der Straße
- Aufzug
- Gepäck kann abgestellt werden
- Überwachungskameras in Außenbereichen auf dem Grundstück

Alle 41 Ausstattungsmerkmale anzeigen

Features

Daten der Berliner AirBnB Ferienwohnungen

Target	Features							
price	eighbourhood_group_cleansed	property_type	room_type	accommodates	bathrooms	bedrooms	number_of_reviews	review_scores_rating
135.0	Pankow	Entire rental unit	Entire home/apt	7	2.5	4.0	7	5.00
202.0	Pankow	Entire loft	Entire home/apt	4	1.0	2.0	140	4.48
152.0	Mitte	Entire rental unit	Entire home/apt	5	1.0	2.0	600	4.81
172.0	Pankow	Entire rental unit	Entire home/apt	8	1.0	2.0	503	4.80
54.0	Friedrichshain-Kreuzberg	Private room in condo	Private room	5	1.5	1.0	32	4.84
...	...	...	...	...	...	...	...	...
63.0	Mitte	Entire rental unit	Entire home/apt	2	1.0	1.0	0	4.60
48.0	Pankow	Private room in rental unit	Private room	2	0.5	1.0	0	4.60
66.0	Charlottenburg-Wilm.	Entire rental unit	Entire home/apt	3	1.0	1.0	0	4.60
63.0	Neukölln	Private room in rental unit	Private room	2	1.0	1.0	0	4.60
45.0	Pankow	Private room in rental unit	Private room	1	1.0	1.0	0	4.60

Quelle: https://insideairbnb.com/

Datenbereinigung

Vor dem eigentlichen Modelltraining muss der Datensatz nach möglichen Problemen untersucht und ggf. bereinigt werden

- Ausreißer: Fewo-Übernachtungspreis von 50.000 Euro
- Fehlende Werte

Überwachtes Maschinelles Lernen

Überwachtes Lernen

Wir kennen den wahren Preis (y) und können daher überwachen bzw. optimieren, wie gut unsere Vorhersage $(\hat{y})$ ist

Optimierungsraum

- Features: Bewertungen, Wohnungsgröße, Bettenzahl
- Modell: Lineare Regression, Entscheidungsbaum, Neuronales Netz, …
- Datenbereinigung: Ausreißer, falsche Werte, …

Lineare Regression

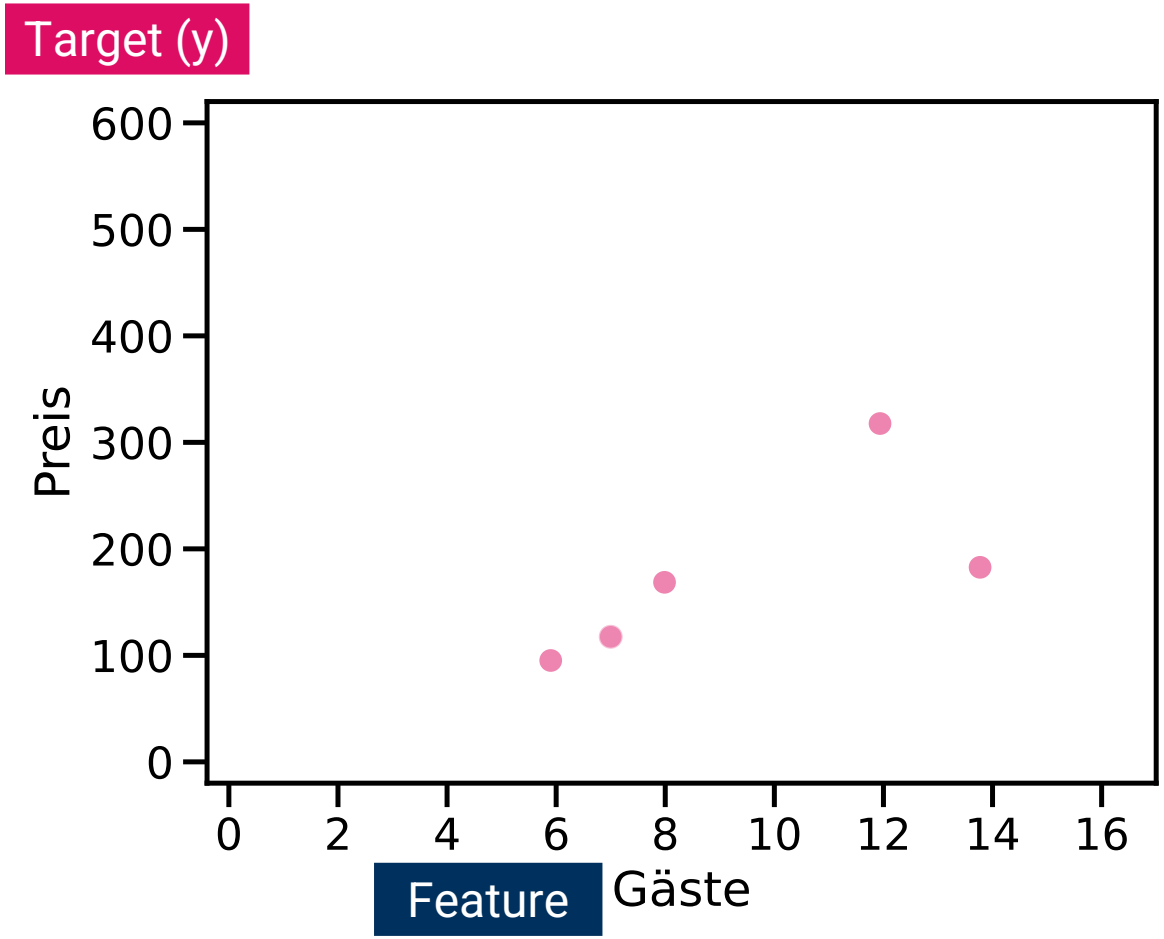

Lineare Regression

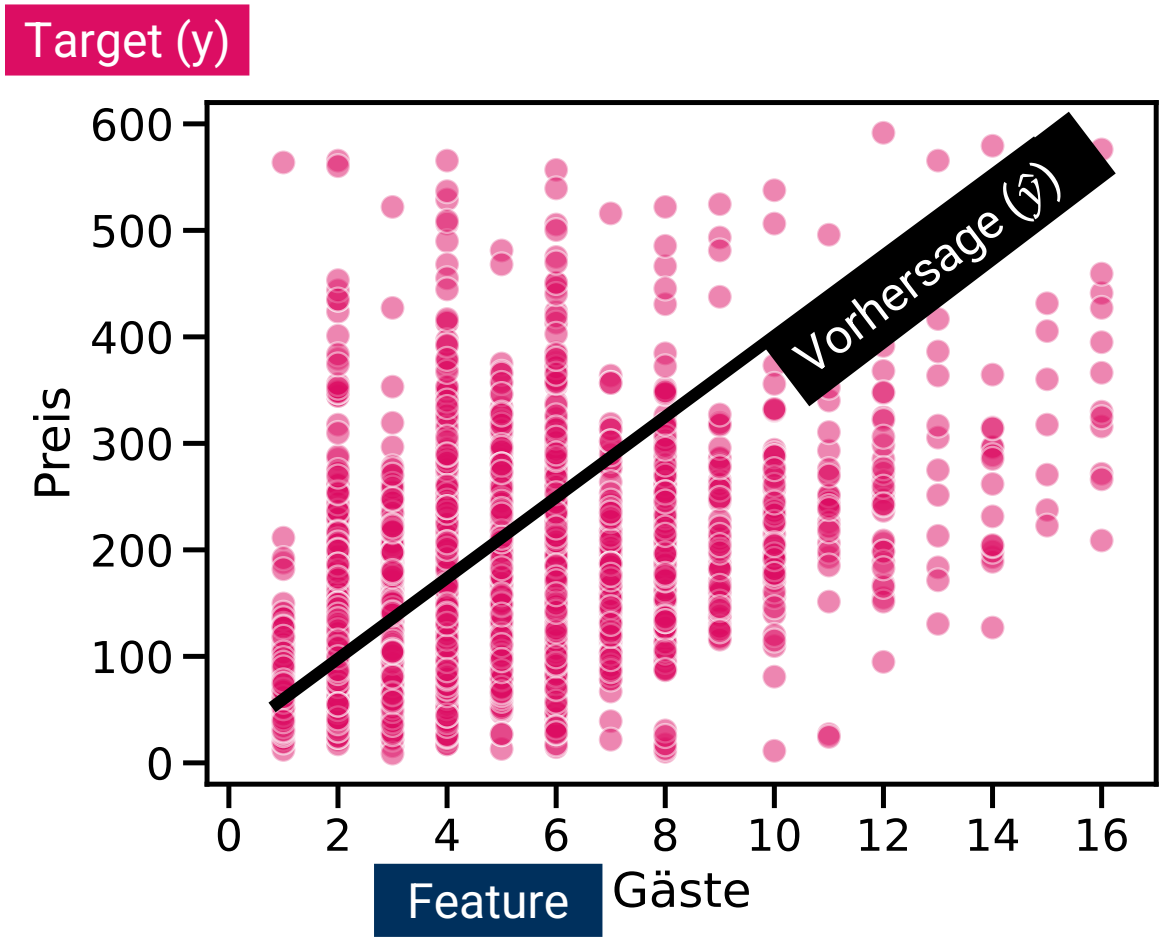

Versucht mit einer **Gerade** zu beschreiben, wie sich der Preis ändert, wenn die Gästezahl steigt

Lineare Regression

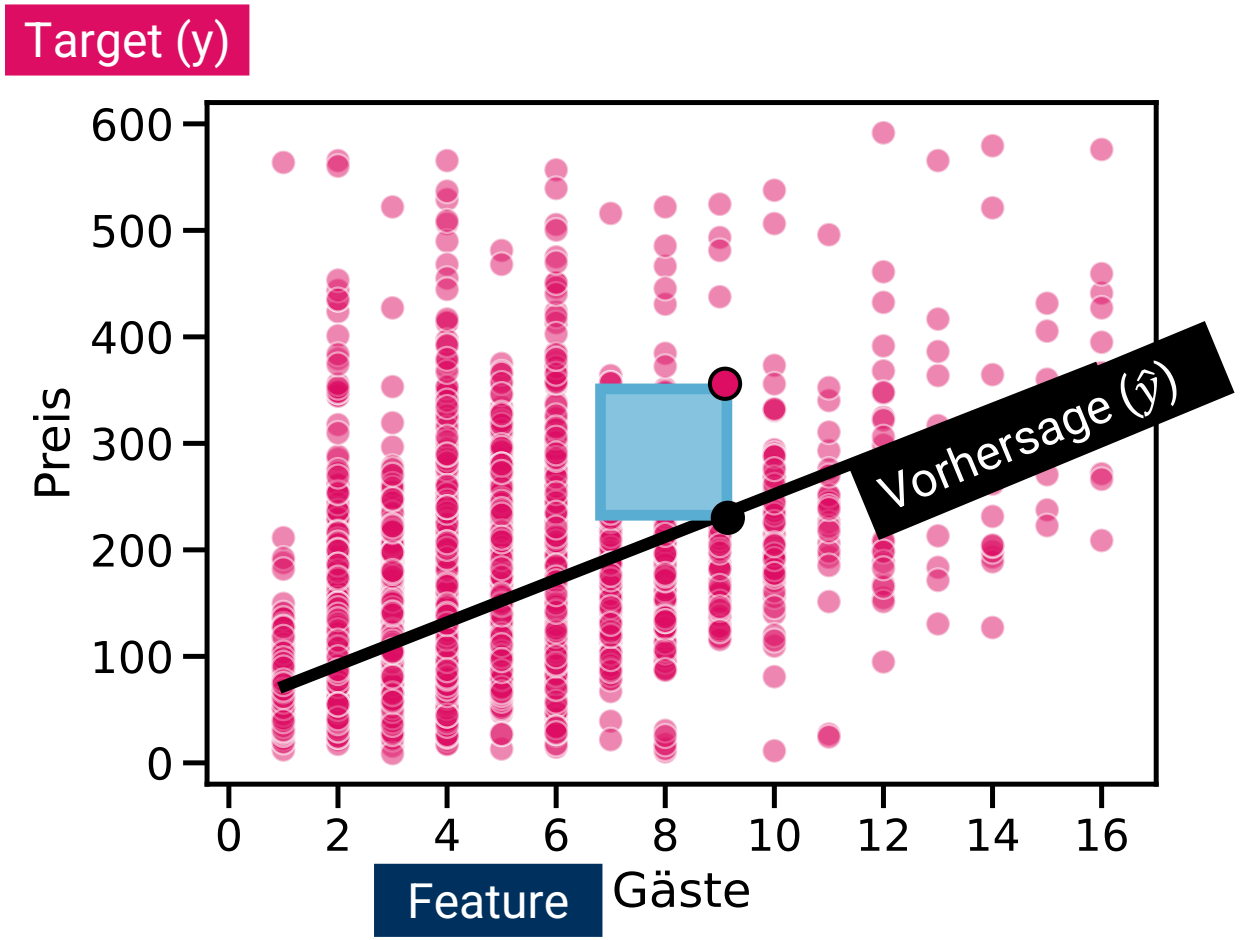

Minimierung der <u>Summe</u> der quadratierten Vorhersagefehler

$$\min \sum \hat{\varepsilon}_i^2 = \min \sum (y_i - \hat{y}_i)^2$$

Ansatz generalisierbar für mehrere „Features“

Mini-Experiment

Modell	Features	Mean Absolute Error (€)
Naive Referenz	Durchschnittspreis (123€)	55
Lineare Regression	Anzahl Gäste	44
	... + Bewertungen	43
	... + Lage + Extras (WLAN, Küche, Arbeitsplatz, Sauna, ...)	36
Random Forest	wie oben	34

Der durchschnittliche, absolute Fehler des besten Modells liegt bei 34€
→ 27% des Durchschnittspreis von 123€

Verbesserungspotenzial?

Hier zeigt sich der gute Data Scientist:

- Warum ist die Vorhersage nicht besser?
- Wie ließe sich die Vorhersage weiter verbessern?

Do not edit
How to change the design

Welche Maßnahme halten Sie für am vielversprechendsten?

The Slido app must be installed on every computer you're presenting from

slido

Do not edit
How to change the design

Welche Maßnahme halten Sie für am vielversprechendsten?

The Slido app must be installed on every computer you're presenting from

slido

Meistens: Datenbereinigung!

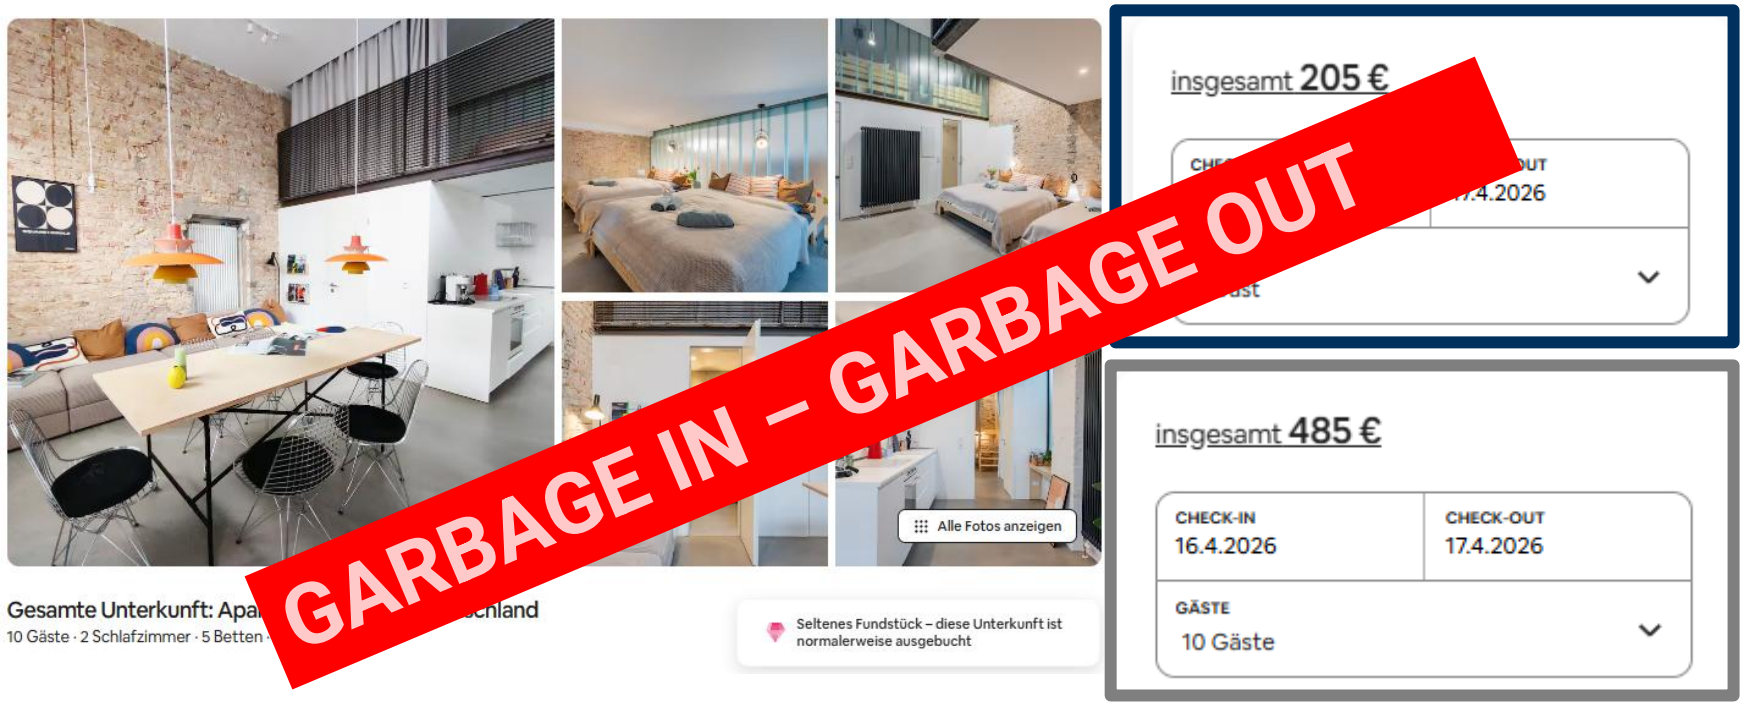

Datenproblem:

- Reale Preise hängen oft von der Gästeanzahl ab
- Preise im Datensatz beziehen sich jedoch immer auf 1 Gast

Sprache
Ein gigantischer aber komplizierter Datenschatz

Was sind „Daten“?

Wenn ich „Daten“ sage: was sehen Sie vor Ihrem inneren Auge?

	A	B	C	D	E
1	**Schüler**	**Klausur1**	**Klausur2**	**Mündlich**	**Gesamt**
2	Anna	1.0	1.5	2.0	1.5
3	Karl	4.0	5.0	2.5	3.8
4	Miran	1.0	1.0	2.0	1.3
5	Kira	3.0	2.5	3.0	2.8
6	Janna	4.0	3.5	3.0	3.5
7	Ercan	2.0	1.5	3.0	2.2
8	Mats	5.0	5.0	3.5	4.5
9	Vincent	2.0	1.5	1.0	1.5

Strukturierte Daten

- **Tabellen** mit Zeilen und Spalten: Excel, csv, relationale Datenbank
- **Zeile** = Entität „Schüler“
- **Spalte** = Merkmal: z.B. Name, Note

→ **Klare Semantik**

Unstrukturierte Daten

Typ
Text, Bilder, Audio, Video

Quelle
Internet, Soziale Medien, Gesetzestexte, Unternehmens-Wikis, Urlaubsfotos, Gesetzestexte, ...

Ausgangslage:
- Der Großteil der weltweit erzeugten Daten sind unstrukturiert
- Potentiell extrem wertvoll
- Nutzbarmachung extrem komplex

Numerische Repräsentation

Um aus Texten Nutzen zu ziehen, benötigen wir numerische Repräsentation

- Klassischer Ansatz: "Bag of Words" Methode
- Matrix aus Worthäufigkeiten

	aus	berlin	berliner	bin	ein	esse	ich
Ich bin ein Berliner.	0	0	1	1	1	0	1
Ich bin aus Berlin.	1	1	0	1	0	0	1
Ich esse Berliner.	0	0	1	0	0	1	1

Was bringt so eine Repräsentation?

Hate Speech Vorhersage Modell

	aus	berlin	berliner	bin	ein	esse	ich	hasse	hate speech
Ich bin ein Berliner.	0	0	1	1	1	0	1	0	0
Ich bin aus Berlin.	1	1	0	1	0	0	1	0	0
Ich esse Berliner.	0	0	1	0	0	1	1	0	0
Ich hasse Berliner	0	0	1	0	0	0	1	1	1
	Features								Target

Schwächen dieses Ansatzes?

Wird der Komplexität von Sprache nicht gerecht!

Wörter sind diskrete Einheiten
Ähnlichkeit von „Berlin“ und „Berliner“ wird nicht erfasst

Polysemie wird ignoriert
Berliner = Mensch oder Pfannkuchen?

Wortreihenfolge wird ignoriert
"Stefanie mag Haie" $\leftrightarrow$ "Haie mögen Stefanie"

KI-Revolution in der Sprachverarbeitung

Bahnbrechende Arbeiten zur Erfassung **komplexer sprachlicher Semantik**, basierend auf **neuronalen Netzen**

Hauptautor	Jahr	Titel	Bekannt für
Bengio	2003	A Neural Probabilistic Language Model	
Mikolov	2013	Efficient Estimation of Word Representations in Vector Space	**Word2Vec**
Vaswani	2017	Attention is all you need	**Transformer**
Radford	2018	Improving Language Understanding by Generative Pretraining	**GPT1**
Brown	2020	Language Models are Few-Shot Learners	**GPT3**

Was ergibt ...

Berlin – Deutschland + Frankreich = ?

Do not edit
How to change the design

Ordne die folgenden Begriffe nach ihrer Ähnlichkeit zum Wort "Berlin" (beginnend mit dem Wort, welches am ähnlichsten ist)

The Slido app must be installed on every computer you're presenting from

slido

Embeddings

Mithilfe von **neuronalen Netzen**, welche aus gewaltigen Textmengen Muster der menschlichen Sprache lernen, können **Embeddings erzeugt werden**

Ein **Embedding** ist eine dichte **Vektorrepresentation** – z.B. eines einzelnen Wortes, eines Satzes, oder eines ganzen Buches

Embedding des Wortes „Berlin“

```
[ 0.069,  0.112, -0.148, ……————————————— 0.025, -0.048, 0.181]
```

- Berlin wird z.B. durch einen Vektor der Dimension D=300 repräsentiert
- **Zahlen kodieren Attribute** (intuitiv: Hauptstadt, Deutschland, Nomen, groß, ...) – lassen sich diesen aber **nicht explizit zuordnen**

Vereinfachte Darstellung

	Land-Hauptstadt	Nationalität
Berlin	3	9
Paris	3	1
Deutschland	8	9
Frankreich	8	1

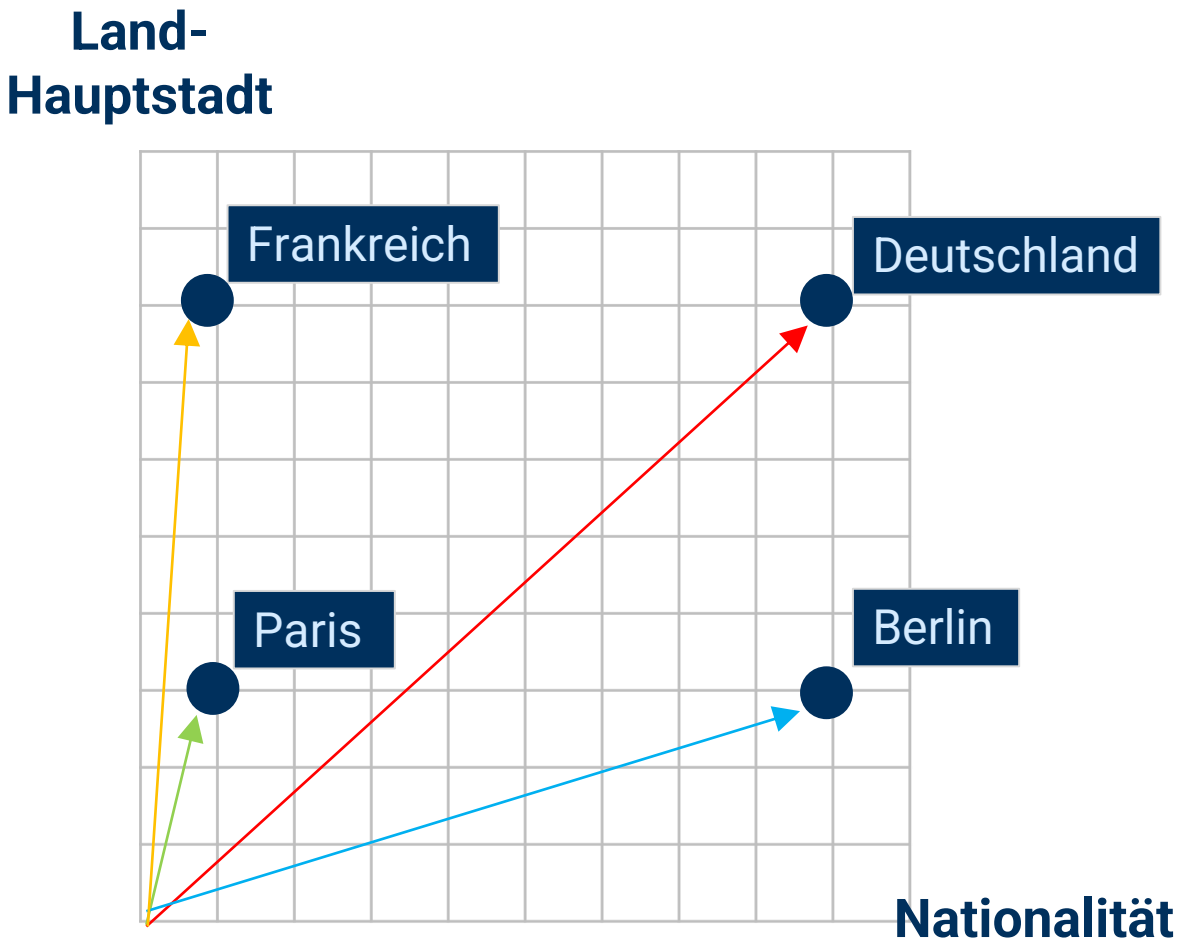

Erfassung semantischer Ähnlichkeit

Der **Winkel zwischen Wortvektoren** repräsentiert Ähnlichkeit
Berlin ist semantisch näher an Deutschland als an Frankreich.

Winkel	cos(Winkel)	Interpretation
0°	1	Identisch
30°	0.87	Sehr ähnlich
90°	0	Unabhängig
180°	-1	Keine praktische Relevanz

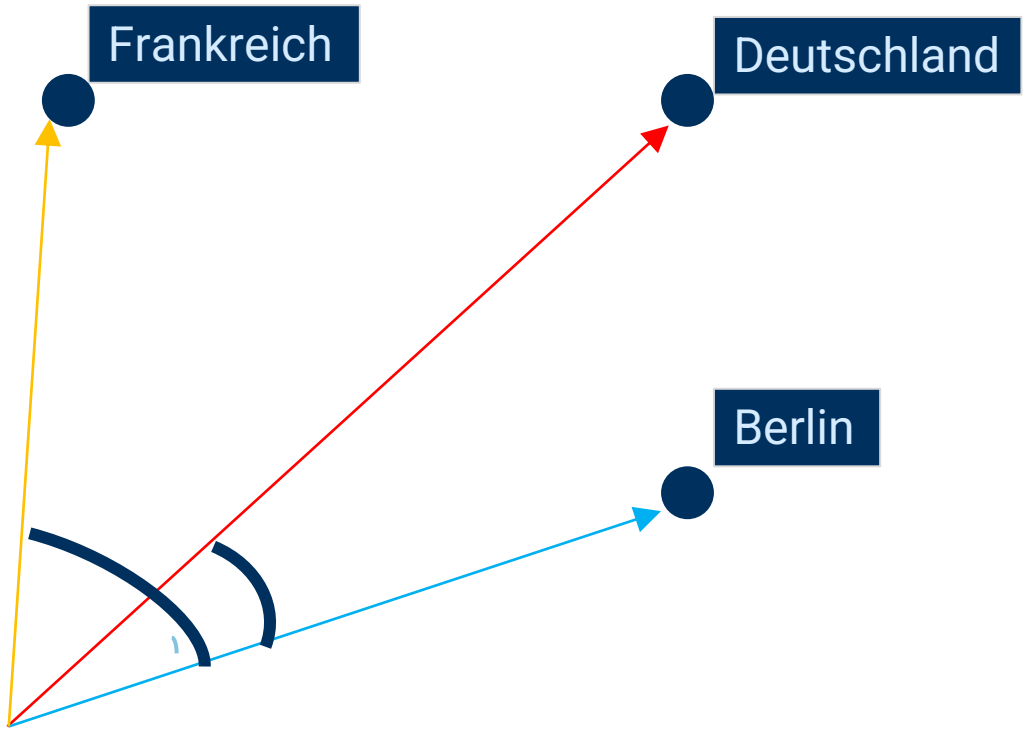

Ähnlichste Wörter zu Berlin laut Word2Vec Embeddings

Platz	Wort	Ähnlichkeit
1	**Munich**	0.70
2	**Leipzig**	0.66
3	**Dusseldorf**	0.63
4	**Stuttgart**	0.62
5	**Berliner**	0.61
6	**Cologne**	0.60
7	**Dresden**	0.59
8	**Frankfurt**	0.57
9	**GDR**	0.57

Winkel(Berlin, Munich) = 45.5°
Kosinus-Ähnlichkeit: cos(45.5) = 0.70

https://vectors.nlpl.eu/explore/embeddings/en/associates/#

Erfassung von Beziehungen

Wir können Beziehungen zwischen Texten (näherungsweise) per Vektorarithmetik darstellen

Berlin

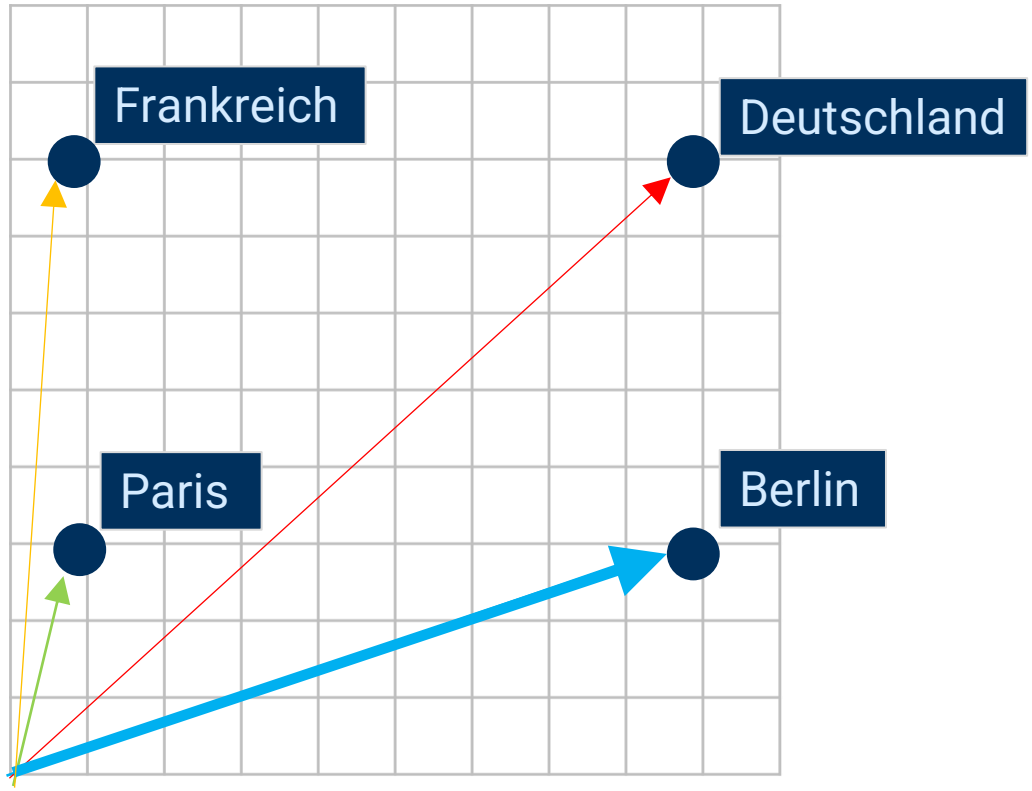

Erfassung von Beziehungen

Wir können Beziehungen zwischen Texten (näherungsweise) per Vektorarithmetik darstellen

Berlin – Deutschland

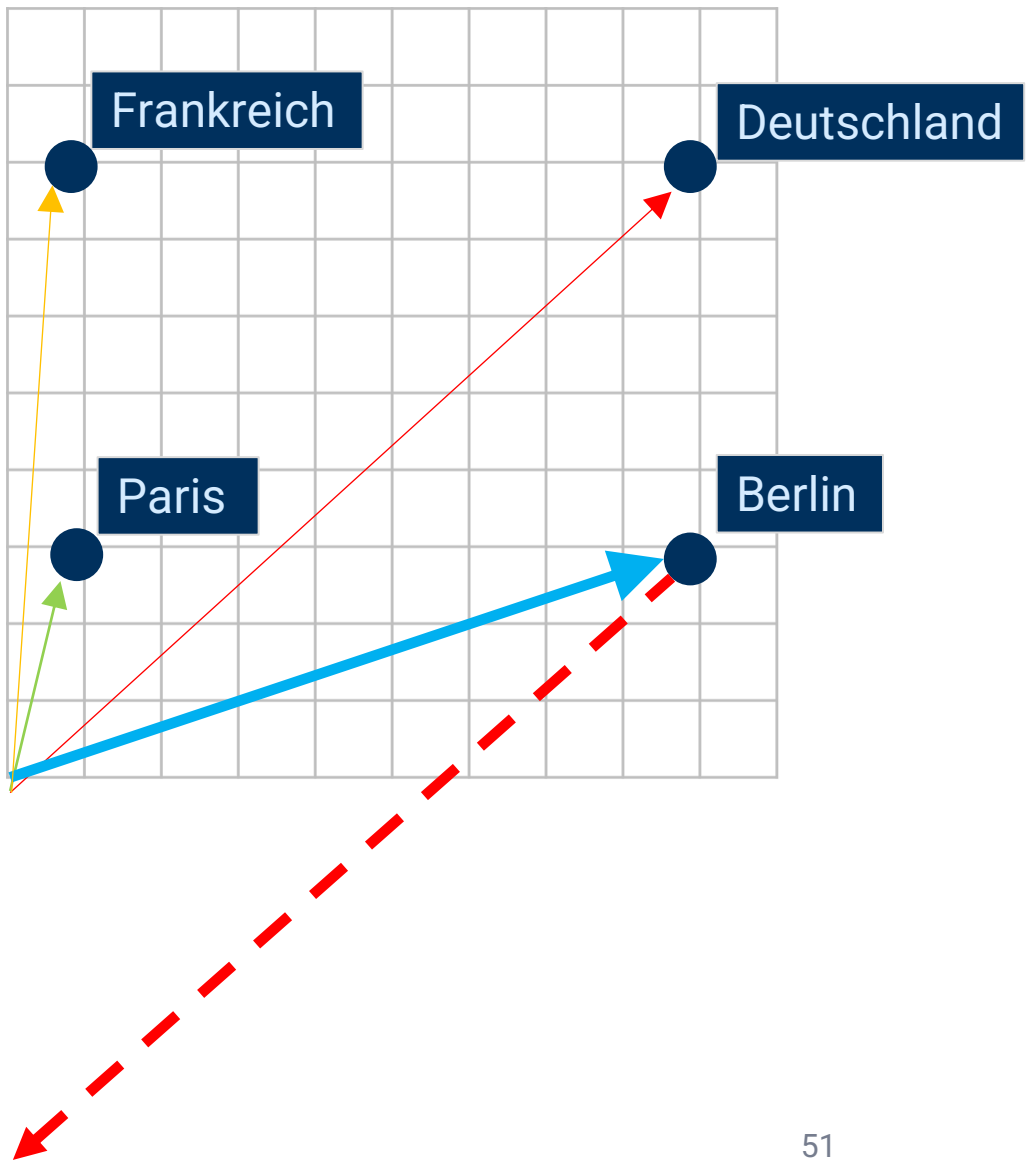

Erfassung von Beziehungen

Wir können Beziehungen zwischen Texten (näherungsweise) per Vektorarithmetik darstellen

Berlin – Deutschland + Frankreich

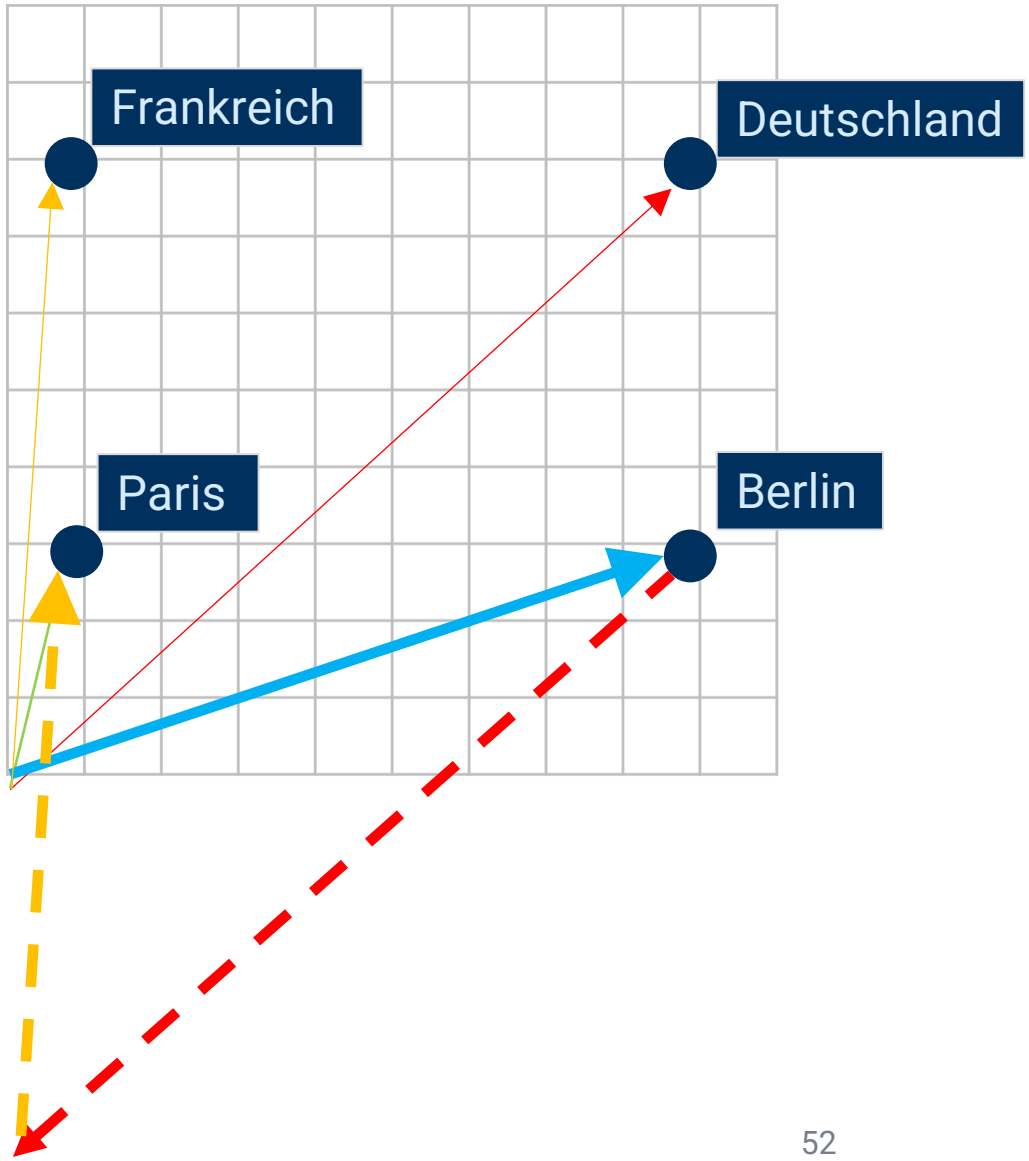

Praktische Anwendungen von Embeddings

Verbesserte Vorhersagemodelle

Hate Speech Vorhersage Modell

	e1	e2	e3	e4	...	e298	e299	e300	hate speech
Ich bin ein Berliner.	0.23	-0.51	0.03	0.11	0.95	0.92	-0.89	-0.32	0
Ich bin aus Berlin.	-0.05	-0.30	0.23	0.01	-0.05	0.89	0.23	0.41	0
Ich esse Berliner.	0.51	0.55	0.23	-0.09	-0.21	0.63	0.74	-0.01	0
Ich hasse Berliner	0.06	0.89	-0.40	0.21	0.33	-0.05	0.06	0.98	1
	Features								Target

https://kimola.com/pretrained-ai-models/hate-speech-detector

Verbesserte Empfehlungssysteme

Empfehlungssystem für Texte (Zeitungsartikel, Bücher, Publikationen, etc.):

"Wenn dir dieser Artikel gefällt, dann empfehle ich dir auch folgenden semantisch ähnlichen Artikel."

Verbesserte Google Suche

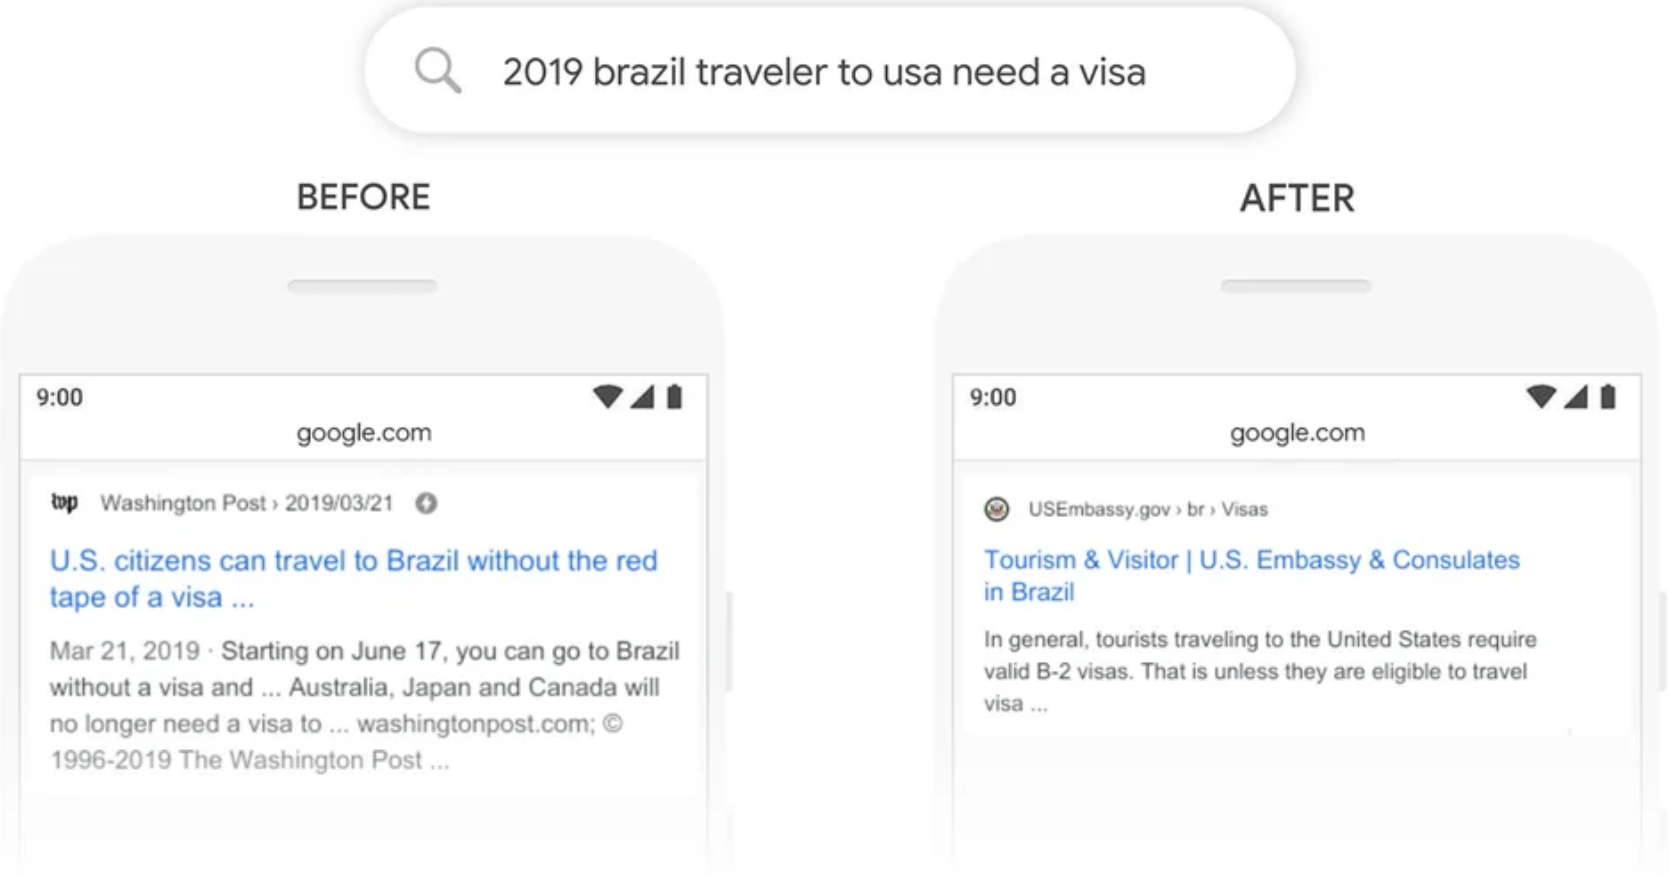

Quelle: [Google Blogpost]

ChatGPT

Embeddings in ChatGPT

- Nutzer lädt ein langes Textdokument hoch und stellt dazu eine Frage
- ChatGPT teilt das Dokument in kleine Abschnitte und embedded diese
- Die "relevantesten Abschnitte" werden von ChatGPT "gelesen" und daraus eine Antwort generiert

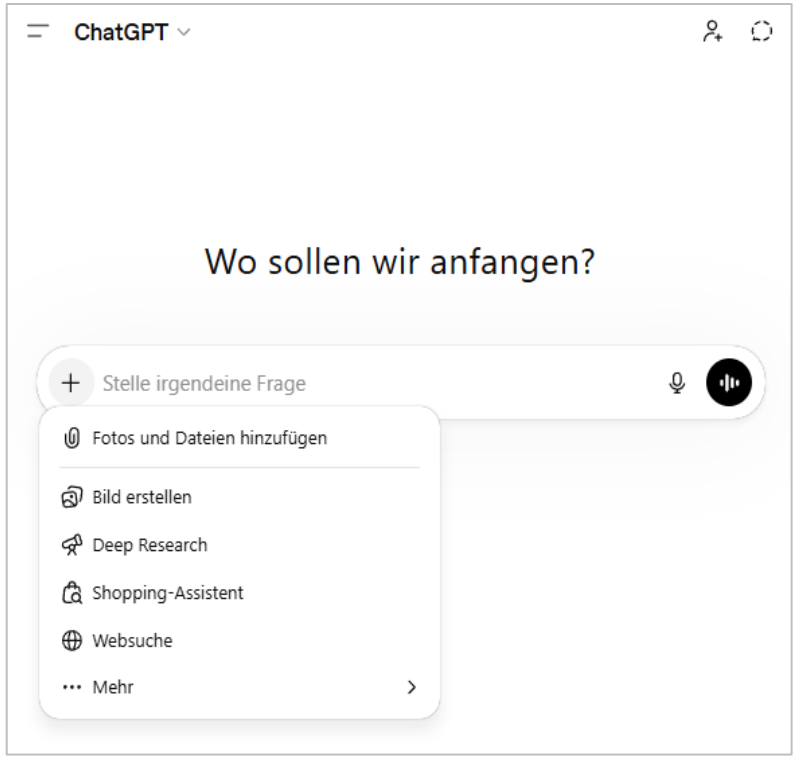

Einschub

Embeddings werden aus dem Training von großen, neuronalen Sprachmodellen (LLMs) gewonnen – aber was passiert bei diesem Training?

Do not edit
How to change the design

Wie geht der Satz weiter: "Am Anfang ..."

The Slido app must be installed on every computer you're presenting from

slido

Training von Sprachmodellen

Aufgabe: Vorhersage des jeweils nächsten Wortes
Trainingsdaten: "Am Anfang schuf Gott Himmel und Erde. Und die Erde war wüst und leer, und Finsternis lag auf der Tiefe"

Input Features	Target
Am	Anfang
Am Anfang	schuf
Am Anfang schuf	Gott
Am Anfang schuf Gott	Himmel
...	...

Überwachtes Lernen: Da das "korrekte" Wort aus dem Text bekannt ist, kann das Lernen überwacht, evaluiert und verbessert werden

Training von Sprachmodellen

Für jedes Wort berechnet das neuronale Netz eine Wahrscheinlichkeit

- Falsche Vorhersage → Parameter des Netzes werden angepasst/verbessert
- Embeddings sind solche Parameter
- Am Ende des Trainingsvorhangs sind sie "bedeutungsvoll"

Platz	Wort	Wahrscheinlichkeit
1	**war**	40%
2	**bin**	25%
3	**schuf**	12%
4	**ging**	9%
...	**...**	...
50.000	**husten**	0.001%
Summe		100%

LARGE language models

Wenn wir Menschen lesen, erlernen wir Sprache und eignen uns Wissen an
→ **Je mehr wir lesen, desto mehr wissen wir**

Große Sprachmodelle sind künstliche neuronale Netze, die darauf trainiert warden, menschliche Sprachmuster zu erlenen
→ **Je mehr Trainingsdaten, desto mehr weiß das Sprachmodell**

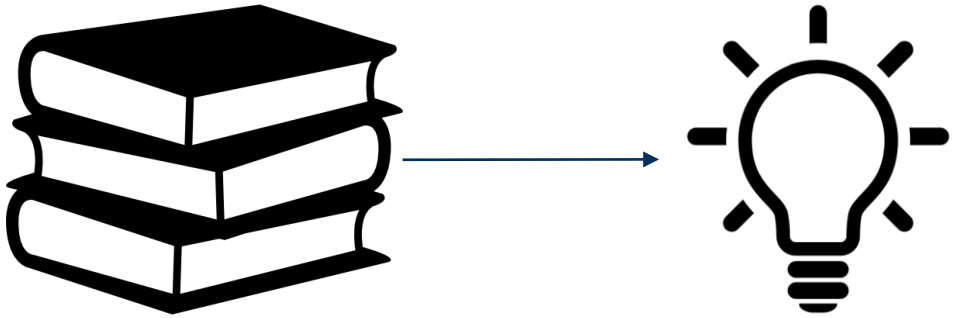

Trainingsdaten

Künstliche Intelligenz (KI), englisch artificial intelligence, daher auch artifizielle Intelligenz (AI), bezeichnet ein Forschungsgebiet der Informatik, sowie daraus hervorgegangene verschiedene Klassen algorithmischer Problemlösungsverfahren, die anhand von Eingaben aus ihrer Umgebung bestimmte Handlungen durchführen. Historisch ist der Begriff nicht einheitlich definiert, sondern kann sich einerseits auf „Intelligenz“ im Sinne der Nachbildung menschlichen Verhaltens beispielsweise bei der Bilderkennung oder der Interaktion in menschlicher Sprache beziehen, andererseits auf die Fähigkeit zu rationalem, logikbasierten Schlussfolgern. In der öffentlichen Wahrnehmung werden häufig maschinelles Lernen und die auf diesem Prinzip aufbauenden Chatbots mit dem Begriff der künstlichen Intelligenz gleichgesetzt. Maschinelles Lernen ist jedoch nur eines mehrerer Teilgebiete des Felds, ihm stehen beispielsweise logik- und regelbasierte Ansätze wie die der symbolischen Künstlichen Intelligenz gegenüber. Mit der Zeit haben sich viele Bereiche zu den Methoden der KI entwickelt. Weiterhin wird unterschieden, welche Probleme mit den Methoden der KI beschrieben werden. Dabei entstanden zwei Bereiche: schwache KI und starke KI. Der ingenieurwissenschaftliche Teil der Informatik befasst sich damit, wie solche Systeme realisiert werden können. Beispiele dafür sind Multiagentensysteme, Expertensysteme, Transformer oder serviceorientierte Architekturen.

ca. 200 Wörter ~ 1 Minute Lesezeit

Die Lektüre von GPT 5 (geschätzt)

Künstliche Intelligenz (KI), englisch artificial intelligence, daher auch artifizielle Intelligenz (AI), bezeichnet ein Forschungsgebiet der Informatik, sowie daraus hervorgegangene verschiedene Klassen algorithmischer Problemlösungsverfahren, die anhand von Eingaben aus ihrer Umgebung bestimmte Handlungen durchführen. Historisch ist der Begriff nicht einheitlich definiert, sondern kann sich einerseits auf „Intelligenz" im Sinne der Nachbildung menschlichen Verhaltens beispielsweise bei der Bilderkennung oder der Interaktion in menschlicher Sprache beziehen, andererseits auf die Fähigkeit zu rationalem, logikbasierten Schlussfolgern. In der öffentlichen Wahrnehmung werden häufig maschinelles Lernen und die auf diesem Prinzip aufbauenden Chatbots mit dem Begriff der künstlichen Intelligenz gleichgesetzt. Maschinelles Lernen ist jedoch nur eines mehrerer Teilgebiete des Felds, ihm stehen beispielsweise logik- und regelbasierte Ansätze wie die der symbolischen Künstlichen Intelligenz gegenüber. Mit der Zeit haben sich viele Bereiche zu den Methoden der KI entwickelt. Weiterhin wird unterschieden, welche Probleme mit den Methoden der KI beschrieben werden. Dabei entstanden zwei Bereiche: schwache KI und starke KI. Der ingenieurwissenschaftliche Teil der Informatik befasst sich damit, wie solche Systeme realisiert werden können. Beispiele dafür sind Multiagentensysteme, Expertensysteme, Transformer oder serviceorientierte Architekturen.

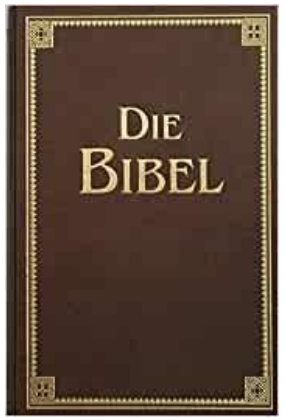

WIKIPEDIA
The Free Encyclopedia

GPT 5

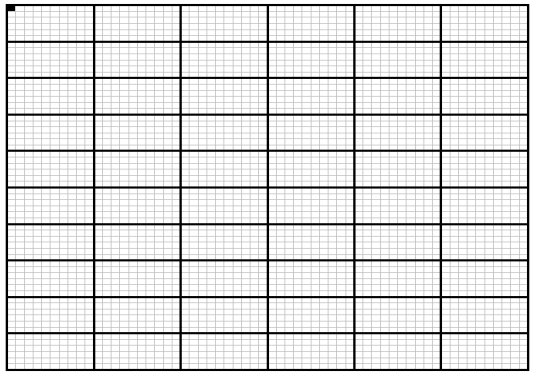

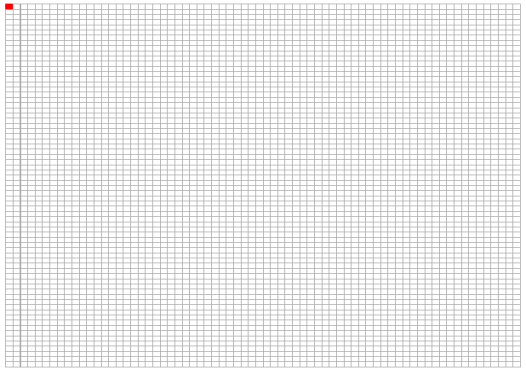

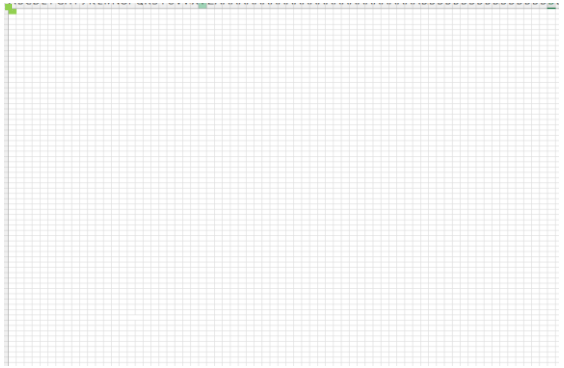

200 Wörter
1 Minute Lesezeit

740 Tausend Wörter
7.7 Tage Lesezeit

4 Milliarden Wörter
114 Jahre Lesezeit

20 Billionen Wörter
7130 Menschenleben

(Weitere) Ideen für den Unterricht

Semantle – Spielerischer Zugang zu Embeddings

Link: https://semantle.com

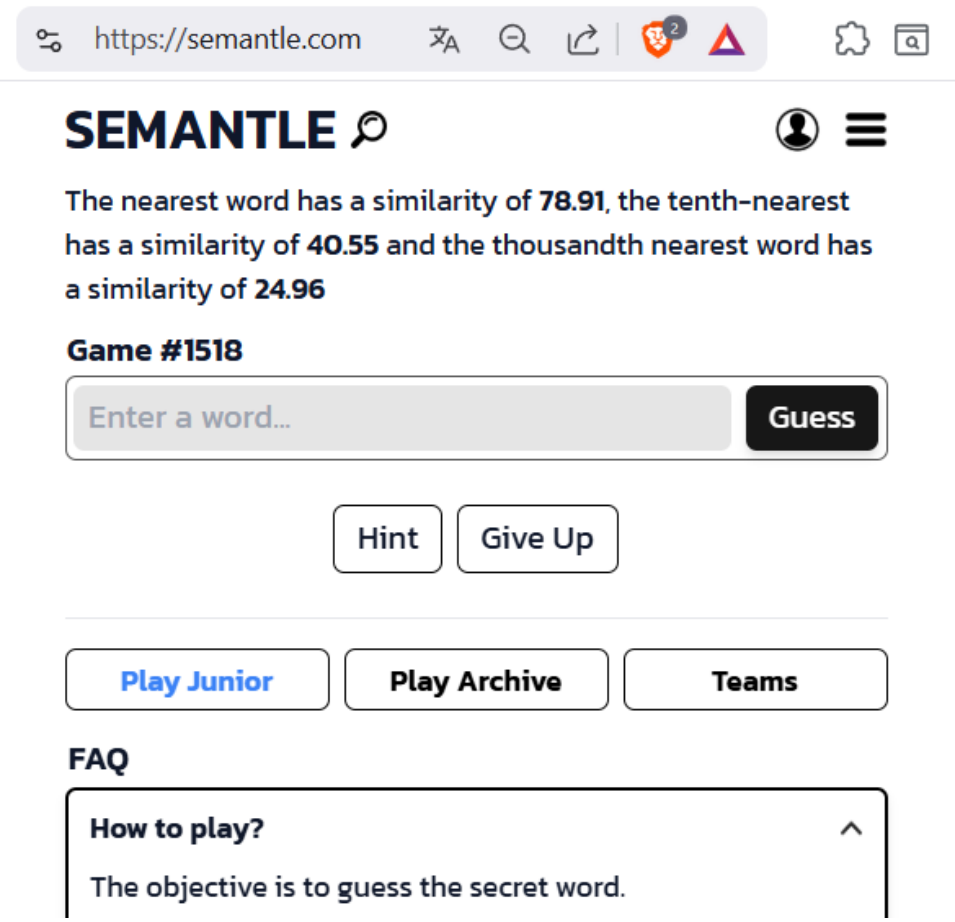

Wortähnlichkeiten

Link: https://vectors.nlpl.eu/explore/embeddings/en/
Aufgabe: Schüler erst schätzen lassen, dann online testen – was sind die semantisch ähnlichsten Wörter zu ___?

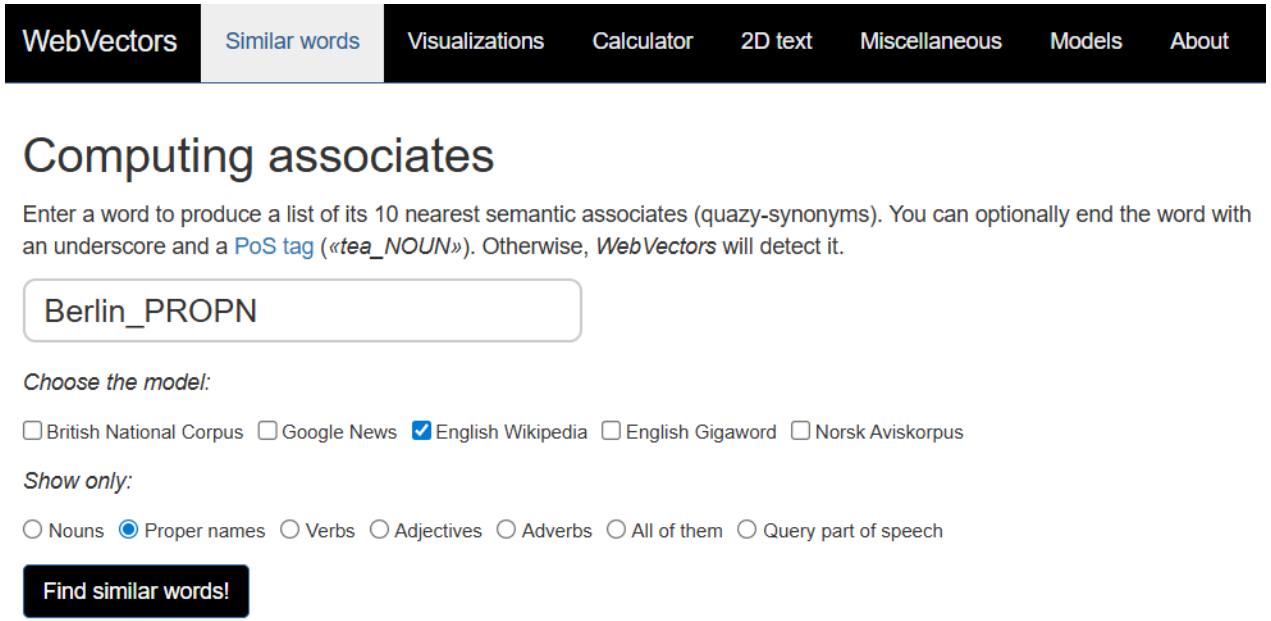

Beziehungen zwischen Wörter

Link: https://vectors.nlpl.eu/explore/embeddings/en/
Aufgabe: Weitere Beziehungen zwischen Wörtern berechnen

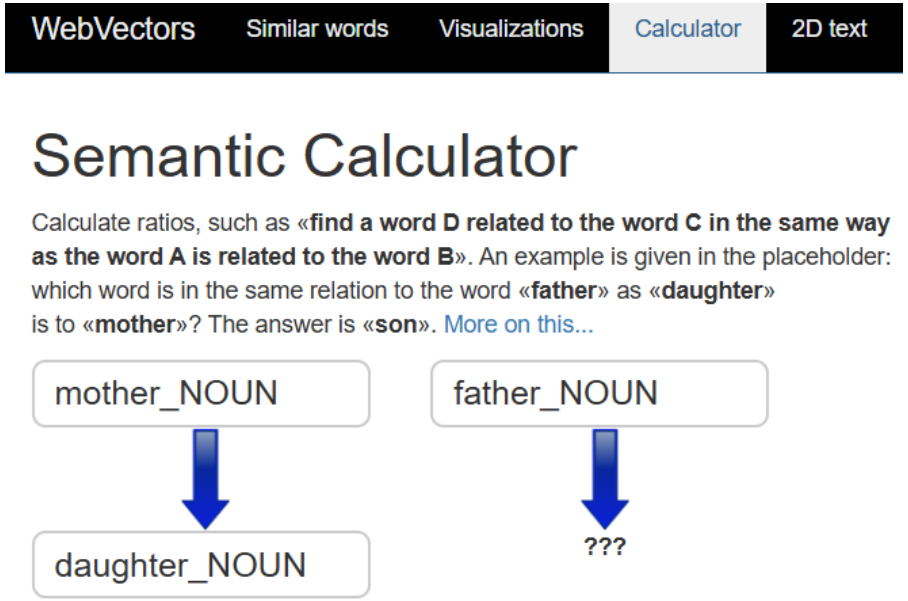

Wie objektiv sind Embeddings?

- Embeddings sind abhängig von den Textdaten, auf denen die Modelle trainiert wurden (z.B. Google News vs. Wikipedia)
- Die Qualität der Trainingsdaten entscheidet über die Qualität der Embeddings

Semantic associates for *love* (NOUN)

Word frequency

☑ High ☑ Medium ☐ Low

Google News	English Wikipedia
1. passion NOUN 0.61	1. lover NOUN 0.67
2. hate NOUN 0.60	2. affection NOUN 0.63
3. llove NOUN 0.57	3. feeling NOUN 0.60
4. affection NOUN 0.57	4. infatuation NOUN 0.59
5. undying love NOUN 0.55	5. passion NOUN 0.59

Diskriminierende Embeddings?

Laut Embeddings:

- Frauen arbeiten im Haushalt
- Männer arbeiten als Programmierer

→ **Warum?** Sie haben das aus den Trainingsdaten "gelernt"
→ Verstärken solche Methoden gesellschaftliche Stereotype?

Extreme *she* occupations

1. homemaker	2. nurse	3. receptionist
4. librarian	5. socialite	6. hairdresser
7. nanny	8. bookkeeper	9. stylist
10. housekeeper	11. interior designer	12. guidance counselor

Extreme *he* occupations

1. maestro	2. skipper	3. protege
4. philosopher	5. captain	6. architect
7. financier	8. warrior	9. broadcaster
10. magician	11. figher pilot	12. boss

Bolukbasi et al (2016), “Man is to computer programmer as woman is to homemaker? Debiasing word embeddings”

Rassistische Embeddings?

Embeddings lernen sprachliche Muster aus Trainingsdaten – auch rassistische Sprachmuster und andere Formen der Diskriminierung!

“[…] extreme impacts of race as indicated simply by name. A bundle of names associated with being European American was found to be significantly easier to associate with pleasant than unpleasant terms, compared to a bundle of African American names”

Caliskan et al., 2017, “Semantics derived automatically from language corpora necessarily contain human biases”

Diskrimienierung, Lügen, Hass

Embeddings und Generative künstliche Intelligenz entstehen durch **überwachtes maschinelles Lernen** auf riesigen Mengen an Textdaten

Sprachmodelle **lernen statistische Muster menschlicher Sprache** – auch Diskriminierung, Lügen, Hass

Wir alle müssen kritisch bleiben:
Stimmt das? Woher kommen die Daten? Was sind die Grenzen von KI?

KI zur Erkennung von Hate Speech

Soziale Netzwerke sind voll von **Hass, Rassismus, und Fake News**

- Können diese mittels KI identifiziert (und gelöscht) werden?
- Sollten Soziale Netzwerke dazu verpflichtet werden?
- Würde dadurch der öffentliche Diskurs zu sensiblen Themen (Geschlechterrollen, Religion, …) gestört, da Posts zu diesen Themen oft fälschlicherweise blockiert werden?

Online Hate Speech Detector: https://kimola.com/pretrained-ai-models/hate-speech-detector